정규 표현식(Regular Expression)

HTML 태그 제거

```
import re

tag ="""
<body>
    <h1>공부해야 할 리스트</h1>
    <ul>
        <li>깃, 깃허브</li>
        <li>알고리즘</li>
        <li>컴퓨터 구조</li>
        <li>자료구조</li>
    </ul>
</body>
"""
sentence = re.sub(r'<.*?>', '', tag)  # sentence = re.sub(r'<[^>]*>', '', tag)
print(sentence)
```

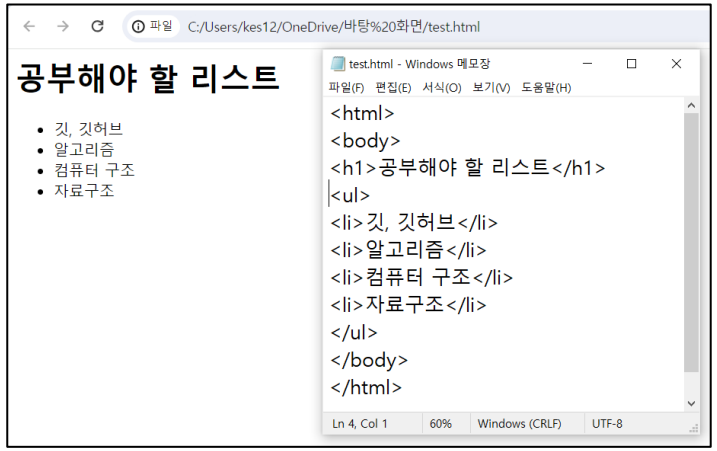


```
공부해야 할 리스트

깃, 깃허브
알고리즘
컴퓨터 구조
자료구조
```

정규 표현식(Regular Expression)

- 일정한 패턴을 가진 문자열을 표현하는 형식.
- 일정한 패턴의 문자열을 검색, 추출, 변경할 때 사용.
- 문자열을 다루는 모든 프로그래밍에 사용되는 공통의 언어.
- 이메일 형식 체크, 전화번호 유형 체크...

모듈 import

```
import re
```

정규 표현식에 사용되는 메타 문자(meta characters)

메타 문자	의미	메타 문자	의미
.	₩n을 제외한 모든 문자	^	시작 문자
?	있거나 없거나	$	끝 문자
*	0개 이상 반복	{m, n}	m회 이상 n회 이하
+	1개 이상 반복	[ ]	문자 클래스
₩	메타 문자를 일반 문자로	( )	그룹 패턴 지정
|	논리 OR		

메타 문자 예제

메타 문자	의미	예제
.	₩n을 제외한 모든 문자	a.b : Dot(.) 위치에 아무 문자나 하나 올 수 있다. aab, a0b, a!b
?	? 앞에 있는 문자가 있거나 없거나	ab?c : "?" 앞에 문자인 "b"가 있거나 없어야 한다. ac, abc
*	* 앞에 있는 문자가 0개 이상 반복	ca*t : "*"기호 바로 앞 문자인 a가 0번 이상 출현해야 한다. ct, cat, caaat
+	+ 앞에 있는 문자가 1개 이상 반복	ca+t : "+"기호 바로 앞 문자인 a가 1번 이상 나와야 한다. cat, caaat
|	논리 OR	abc | def : abc 또는 def
₩	메타 문자를 일반 문자로	\. : .문자로 \ ? : ? 문자로

메타 문자 예제

메타 문자	의미	예제
^	^기호 뒤의 문자로 시작하는지	^a : a로 시작하면 매치됨 aab, a0b, a!b
$	$기호 앞의 문자로 끝나는지	a$: a로 끝나면 매치됨 bba, nana,00a
{m, n}	{m,n}앞의 문자가 m회 이상 n회 이하인지	go{2, 4}d : o가 2~4번 출현해야 매치됨 good, goood, gooood
[ ]	[ ] 기호 안에 나열된 문자가 있는지 (문자 집합을 지정)	[abc] : 문자열에 a, b, c 중 하나가 있으면 매치됨 a, boy, day [a-c] : [abc]와 동일함. [a-zA-Z] : 모든 알파벳 [0-9] : 숫자 [ ]안에서 "^"는 반대를 뜻함. [^0-9] : 숫자를 제외한 문자
( )	그룹 패턴 지정	(abc)+ : "abc", "abcabc", "abcabcabc", 등과 매치

문자 클래스의 축약 기호

기존 표현식	축약 표현	설명	사용
[0-9]	**\d**	숫자	숫자
[^0-9]	**\D**	숫자가 아닌 것	문자, 특수문자, whitespace
[\t\n\r\f\v]	**\s**	whitespace 인 것	space, TAB, 개행
[^\t\n\r\f\v]	**\S**	whitespace가 아닌 것	문자, 특수문자, 숫자
[a-zA-Z0-9]	**\w**	문자나 숫자	문자, 숫자
[^a-zA-Z0-9]	**\W**	문자나 숫자가 아닌 것	

\b: 단어 경계를 나타냅니다. 단어 문자와 비단어 문자 사이의 경계를 찾는 데 사용됩니다.

\B: 단어 경계가 아닌 부분에 대응됩니다.

메타 문자 : . , ?

```
### 1. Dot(.) : "."위치에 "\n"을 제외한 임의의 한 문자
import re
p="a.b"
s="a&b"
s="a9b"
s="a99b"     # None
print(re.search(p,s))

### 2. ? : "?" 기호 앞에 있는 문자가 있거나 없는 패턴.
import re
p="ab?c"    # ? 앞에 있는 문자인 "b"가 있거나 없는
s="ac"
s="accc"
s="acccd"  #ac가 있으므로 매치됨
print(re.search(p,s))
```

메타 문자 : * , +

```
### 3. * : "*" 기호 앞에 있는 문자가 0번 이상 출현하는 패턴.
import re
p="ca*t"    # * 앞에 있는 문자이 a가 0번 이상 출현해야 함
s="ct"
s="cat"
s="caaat"
s="caaats"
s="caaagt"  # c와 t 사이에 a외에 다른 문자는 못오므로 None
print(re.search(p,s))

### 4. + : "+" 기호 바로 앞에 있는 문자가 1번 이상 출현해야 함.
import re
p="ca+t"
s="cat"
s="caaats"
s="ct"  # a가 없으므로 None
print(re.search(p,s))
```

메타 문자 : | , ^

```
### 5. | : or
import re
p="cat|dog"
s="cats"
s="dog"
s="cute dog"
print(re.search(p,s))

### 6. ^ : ^ 기호 뒤에 오는 문자로 시작하는지
import re
p="^a"
s="ab"
s="a0b"
s="sab"      # a로 시작하지 않으므로 None
print(re.search(p,s))
```

메타 문자 : $, {m, n}

```
### 7. $ : $ 기호 앞에 오는 문자로 끝나는지
import re
p="a$"
s="bba"
print(re.search(p,s))

### 8. {m,n} : {}앞의 문자가 m~n회 사이 출현
import re
p="go{2,4}d"
s="good"
s="goood"
s="gooood"
s="goooood"  # "o"가 2~4번만 가능하므로 None
print(re.search(p,s))
```

메타 문자 : [ ] , ( )

```
### 9. [ ] : [ ] 사이의 문자가 있으면 됨.
import re
p="[abc]"
s="have a good day"
s="good"   # a, b, c 문자가 없으므로 None
s="boy"
print(re.search(p,s))

### 10. () : 그룹 지정
import re
p="(abc)+"
s="abc"
s="abcabc"
s="1 xabc11"
print(re.search(p,s))
```

문자 시퀀스

\d: 숫자(digit)에 대응됩니다. 0부터 9까지의 모든 숫자를 포함합니다.

\w: 단어 문자(word character)에 대응됩니다. 문자, 숫자, 밑줄(_)을 포함합니다.

\s: 공백 문자에 대응됩니다. 공백, 탭, 개행 문자 등을 포함합니다.

\D: 숫자가 아닌 문자에 대응됩니다.

\W: 단어 문자가 아닌 문자에 대응됩니다.

\S: 공백이 아닌 문자에 대응됩니다.

문자 시퀀스: \d , \w

```
### 11. [0-9] == \d  : 숫자 지정
import re
p="[0-9]"
p="\d"     # p="[\d]"와 동일
s="1"
s="111"
s="a111"
s="abc"   # 숫자가 없으므로 None
print(re.search(p,s))

### 12. [a-zA-Z0-9] ==  \w  : 문자나 숫자가 있으면 됨.
import re
p="[a-zA-Z0-9]"
p="\w"  # p="[\w]"와 동일
s="한글입니다"
s="!123!"
s="!@$"  # 문자나 숫자가 없으므로 None
print(re.search(p,s))
```

문자 시퀀스: \s

```
### 13. [\t\n\r\f\v] == \s : whitespace 가 있으면 됨.
import re
p="\s"        # p="[\t\n\r\f\v]"
s="hi\n!!!"
s="hello\twow!!!"
print(re.search(p,s))
```

문자 시퀀스: [^]

```
### 14. [^ ] :  [ ] 기호 안에 "^"는 반대의 의미
import re
p="\D"   # [^0-9] == [\D]
s="123"     # 숫자가 아닌 문자가 있어야 하는데 문자가 없으므로 None
s="12a"
print(re.search(p,s))

p="\S"    # [^\t\n\r\f\v]  == [\S]
s="\n"      # None
s="\nhi\n"
s=" "       # None
s='a'
print(re.search(p,s))

p="\W"    # [^a-zA-Z0-9] ==  [\W] : 문자나 숫자가 아닌
s="hello!"
s="안녕"   # 문자나 숫자가 아닌 것이 없으므로 None
print(re.search(p,s))
```

문자 시퀀스: \b

```
### 15. \b : 단어 경계
import re
p=r"\byou\b"     # you 단어가 있으면 됨
s="are you ready?"
s="your book"        # None
print(re.search(p,s))

p=r"\byou"  # you로 시작하면 됨
s="it is your book"        # you가 있으면 됨
print(re.search(p,s))

p=r'\byou\b'    # \b는 한글, 영문, 숫자를 제외한 문자열로 둘러싸인 문자
s='you! book'      # you 주변에 한글, 영문, 숫자가 없으므로 match
s='you&me book'
s='\nyou\tbook'
s='나you우리book'  # you 주변에 한글이 있으므로 None
print(re.search(p,s))
```

re의 주요 메서드들

re모듈의 주요 메서드

- compile : 정규식을 컴파일합니다. 이렇게 하면, 같은 패턴을 여러 번 사용할 때 성능이 향상됩니다.
- search : 문자열에서 정규식과 일치하는 첫 번째 부분을 찾습니다. 일치하는 항목이 없으면 None을 리턴합니다.
- match : 문자열의 시작 부분에서 패턴과 일치하는 부분을 찾습니다. 일치하는 항목이 없으면 None을 리턴합니다.
- findall : 패턴과 매치되는 모든 부분을 찾아 리스트로 반환합니다.
- finditer : 패턴과 매치되는 모든 부분을 찾아 이터레이터로 반환합니다.
- sub(pattern, repl, string, count=0) : string에서 pattern과 일치하는 부분을 replace 텍스트로 교체합니다. count 매개 변수를 사용하여 교체 횟수를 제한할 수 있습니다.
- split(pattern, string, maxsplit=0) : pattern을 기준으로 string을 분리하고, 분리된 문자열 리스트를 반환합니다. maxsplit 매개 변수를 사용하여 분할 횟수를 제한할 수 있습니다.

match, fullmatch

```
### match(p,s) : s가 p로 시작하는지 검사
p='a'
s="abc"
s="bcd"      # a로 시작하지 않으므로 None
print(re.match(p,s))

### fullmatch(p,s) : 문자열 전체가 패턴과 일치하는지 검사
p="abc"
s="abc"
s="abc def"      # 정확히 abc만 있어야 하므로 None
print(re.fullmatch(p,s))

### match vs fullmatch
p="\d{2,3}-\d{3,4}-\d{4}"
tel1="02-1234-12345"
print(re.match(p,tel1))
print(re.fullmatch(p,tel1)) # 마지막에 5개의 숫자가 왔으므로 None
```

search

```
### search(p,s) : search는 포함하고 있는지 검사
p='a'
s="abc"
s="bcdaa"
s="bcd"      # a가 포함되어 있지 않으므로 None
print(re.search(p,s))

### match vs search
p="me"
s="help me!!!"
print(re.match(p,s))     # me로 시작되지 않으므로 None
print(re.search(p,s))
```

findall

```
### findall : 패턴과 매치되는 모든 것을 찾아 리스트로 반환
p=r'\w*apple\w*'
s="apple banana pineapple april"
print(re.findall(p,s))      # ['apple', 'pineapple']

# findall 응용(이메일주소 찾기)
p= r'\b[A-Za-z0-9._%+-]+@[A-Za-z0-9.-]+\.[A-Z|a-z]{2,}\b' # r'\b\S+@\w+\.\w{2,}\b'
s = """
이메일 목록:
john.doe@example.com
jane_doe123@company.org
info@website.net
"""
print(re.findall(p,s))

# 단순 문자열이 아닌 패턴으로 찾기
p=r'[가-힣a-zA-Z]{3,}'    # 한글과 알파벳 문자중 3자 이상인 것
s='abc def*efg 문자열 1234 패턴으로 분리'
print(re.findall(p,s))    # ['abc', 'def', 'efg', '문자열', '패턴으로']
```

"."문자 자체로 인식하도록 설정하기 위해

sub

```
### sub : 패턴과 매치되는 것을 바꾸기
p="apple"
s="apple banana pineapple april"
print(re.sub(p,"애플",s))  # 애플 banana pine애플 april

# sub 응용(sub로 공백삭제하기)
word = 'I am  home now. \n\n\nI am with my cat. \n\n'
# print(word)
# p="\n| "
p=r'\s+'
print(re.sub(p,' ',word))
```

split, finditer

```
### split : 지정한 패턴으로 문자열을 분리해서 리스트로 반환
p=' '
s="I am with my cat."
print(re.split(p,s))
# maxsplit로 분할 횟수 지정
print(re.split(p,s,2))   # ['i', 'am', 'with my cat.']


### finditer : 지정한 패턴을 찾아 이터레이터 객체를 반환
p = r'\d+\s'
s = '1234 5678 1313'
result=re.finditer(p, s)
print(re.finditer(p, s))
print([x.group() for x in result])
```

응용(friends 대본의 대화 내용 추출)

```
### 대본 대사 추출
# https://fangj.github.io/friends/ 에서 101 Monica Gets A Roommate 다운로드
import re

# 파일 읽고 대화 추출
f=open('friends101.txt')
script=f.read()
print(script)
monica_script=re.findall(r'Monica:.+',script)
f.close()

# 대화 저장
f=open('monica.txt','w')
for monica in monica_script:
    f.write(monica+'\n')

f.close()
```

응용(전화번호 체크)

```
import re

### 전화번호 체크
tel="02-1234-5678"
p=r'\d{2,3}-\d{3,4}-\d{4}'
if re.fullmatch(p,tel):
    print(f"{tel}은 유효합니다.")
else:
    print("연락처 형식에 맞지 않습니다.")
```

응용(이메일 주소 체크)

```python
import re
### 이메일 주소 체크
email='happy!@seoul.na'
p=r'^[a-zA-Z0-9.!_%+-]+@[a-zA-Z0-9.-]+\.[a-zA-Z]{2,}$'
p=r'^[^\s@]+@[^\s@]+\.[^\s@]+$'
if re.fullmatch(p,email):
    print(f"{email}은 유효합니다.")
else:
    print("이메일 형식에 맞지 않습니다.")
```

```
r'^[^\s@]+@[^\s@]+\.[^\s@]+$'
```

```
^[^\s@]+ : 공백과 @기호가 아닌 한 글자 이상의 문자열로 시작
@ : @
\. : .
[^\s@]+$ : 공백과 @기호가 아닌 한 글자 이상의 문자열로 끝
```

응용(연락처 추출 및 보안 처리)

```
import re

memo="박준서 서울 거주중인 16세 소년이며 연락처는 010-1234-
5678입니다. 긴급 연락처는 010-3333-5555입니다."
# 연락처만 추출하기
phone=re.findall(r'(\d{3}-\d{4}-\d{4})',memo)
print(phone)
# 연락처 뒤 4자리 숫자 보안처리하기
security=re.sub(r'(\d{3}-\d{4}-)\d{4}',r'\1****',memo)
print(security)
```

['010-1234-5678', '010-3333-5555']
박준서 서울 거주중인 16세 소년이며 연락처는 010-1234-****입니다. 긴급 연락처는 010-3333-****입니다."